

基于大语言模型与专家知识注入的博弈决策智能体设计与跨场景验证

章梦瑶¹ 马玮彧¹ 曾勇程¹ 林 舒¹ 张海峰^{1*}

摘要 文章旨在探索基于大语言模型的博弈决策智能体结构设计方法,并在相关场景中验证其有效性。所提方法使用大语言模型进行博弈决策,通过状态文本表征、动作文本表征、专家知识注入、有监督微调训练等方法搭建智能体,结合游戏场景模拟进行验证。结果显示,该智能体结构在不同场景下均表现出良好的适应性和性能。基于该结构构建的博弈决策智能体能够有效处理复杂决策问题,并为实际应用提供了可行的解决方案。

关键词 大语言模型, 博弈决策, 智能体结构设计, 场景验证

Structure Design and Scenario Verification of Game Decision-Making Agent Based on Large Language Models

ZHANG Meng-Yao¹ MA Wei-Yu¹ ZENG Yong-Cheng¹ LIN Shu¹ ZHANG Hai-Feng^{1*}

Abstract This work aims to explore the design methodology of game decision-making intelligent agents based on large language models and validate their effectiveness in relevant scenarios. The proposed method utilizes large language models in game decision-making, and constructs agents through techniques such as state text representation, action text representation, expert knowledge injection and supervised fine-tuning, and then validating it through game scenario simulations. The results demonstrate that the agent structure exhibits good adaptability and performance across different scenarios. It indicates that the decision-making agents based on this structure can effectively process complex decision-making problems and provide feasible solutions for practical applications.

Key words large language model, game decision-making, agent structure design, scenario verification

0 引言

近几年,大语言模型技术蓬勃发展,在对话问答、自动摘要、文本生成等诸多

领域已经有广泛的应用。在博弈决策领域,大语言模型同样具有潜在的应用空间,特别是以大语言模型为基础构建智能体处理复杂表征的博弈决策问题。本研究的主要思路是,设计基于大语言模型的博

* 通信作者

1. 中国科学院自动化研究所

1. Institute of Automation of the Chinese Academy of Sciences

弈决策智能体结构,将大语言模型与特定业务场景的决策数据相结合构建智能体,使智能体能够执行决策任务,形成基于大语言模型的博弈决策流程,并且在多个场景中设计实验验证智能体结构的有效性。

1 研究背景

博弈决策是人工智能领域最困难,也是最重要的研究内容之一,其应用覆盖日常工作和生活的方方面面:小到驾驶路线规划、体育竞技对抗,大到经济政策调整、国防外交博弈。能否较好地支持博弈决策,是任何一种通用人工智能方法所必须具备的关键能力之一。

大语言模型作为一种新兴的技术,被公认为具有成为通用人工智能基座的巨大潜力。然而,目前将大语言模型用于博弈决策的研究仍处于起步阶段,大语言模型在博弈决策中的优势与特点有待进一步开发。

1.1 博弈决策问题的特点

决策问题是在复杂和不确定的环境中进行有效的决策和行动的一类重要问题。对于参与决策的智能体来说,需要同时具备以下两种重要能力。

(1) 认知能力:对环境状态和可选动作的分析和理解能力。

(2) 决策能力:利用专家知识或历史数据进行推理、规划等能力。

博弈决策问题是引入了多方竞争或合作的一类决策问题。在博弈决策问题中,智能体在决策时需要充分考虑其他参与方的对抗或配合,这使得做出理性、有效的决策成为一项更加复杂而具有挑战性的任务。

1.2 博弈决策问题的解决方法

博弈决策问题现有的解决方法包括运筹优化算法和强化学习算法^[1-3]等。运筹优化算法主要采用博弈论、约束满足、组合优化等数学工具求解最优或较优策略,理论性强,不需要额外训练,但需要一定的专家知识,且在实际决策过程中往往计算复杂度高。强化学习算法在与环境交互采样的过程中优化自身策略,专家知识需求小且计算复杂度低,但需要采样大量数据进行策略训练,且跨任务泛化能力较弱。

大语言模型的发展为构建博弈决策智能体提供了一种新的可能途径。使用大量语料预训练形成的大语言模型,具有较强的自然语言理解、通用知识推理等能力。充分发挥大语言模型的优势,可以显著减少博弈决策智能体构建过程中对专家知识、训练数据的依赖,并增强智能体结构的泛化能力。

本文设计的基于大语言模型的博弈决策智能体结构,利用环境状态文本表征和环境动作状态表征技术,并结合大语言模型自身的自然语言文本理解优势,提升了智能体的认知能力;采用专家知识注入和有监督微调训练技术,引入运筹优化、强化学习辅助大语言模型完成推理和学习,提升了智能体的决策能力。

2 相关工作

本文重点关注基于大语言模型设计博弈决策智能体结构,并针对特定场景构建博弈决策智能体。与本文相关的研究工作可分为两类,一是关于大模型用于博弈决策的相关工作,二是关于特定场景智能体研发的相关工作。

2.1 大模型用于博弈决策的相关工作

现有的将大模型用于博弈决策的相关工作主要从两个方面开展，分别为大决策模型（Large Decision Model, LDM）和大语言模型智能体（Large Language Model agent, LLM agent）。

大决策模型的相关工作多采用端到端的训练方式，将不同场景下的状态-动作原始数据直接作为训练数据，对大模型进行预训练，依靠训练数据的跨场景广度覆盖性保证大模型的泛化能力。代表性工作如多模态联合训练 Gato^[4]、DB-1、RT 等，研究在多模态数据上预训练大模型；将预测作为决策的 Video Diffusion^[5]、CogAgent^[6] 等，研究将决策问题转化为预测生成问题；多模型集成的工作如 Say-Can^[7]、LM-Nav^[8] 等，研究多模态预训练大模型协同。

大语言模型智能体的相关工作多是将不同场景下的状态-动作原始数据转化为文本，对大语言模型进行微调训练，利用大语言模型的通用文本处理能力保证泛化

能力。例如，基于大语言模型的 AI 智能体 AutoGPT、Semi-Auto GPT 等，研究大语言模型记忆、规划、使用工具能力的提升；使用大语言模型完成任务分解的 ReAct^[9]、CoT^[10]、ToT^[11] 等，研究大语言模型任务分解、顺序执行能力的提升；基于大语言模型的决策框架如 MetaGPT^[12] 等，研究大语言模型推理能力的提升。

上述两个方向在实际应用中各有优劣，对比分析如表 1 所示。大决策模型具有精确度高、结构和规则清晰等优点，但是领域受限，大多数大决策模型只适用于特定领域或问题，难以泛化到其他领域或应用场景。此外，构建和维护大决策模型需要大量的数据和计算资源，成本较高。大语言模型智能体基于大规模文本数据进行训练，具有一定泛化能力，可以适应各种不同的任务和应用场景。同时，它能够自动学习语言和语境之间的关系，无须人工标注大量数据，可以降低建模成本。它还具有一定灵活性，通过微调或迁移学习等技术，快速适应新的任务或领域。然而，它也有数据依赖性强、对抗攻击风险较高等缺陷，这也是亟待提高的方面。

表 1 大决策模型和大语言模型智能体的对比分析

相关工作	算力需求	数据需求	可解释性	泛化性
大决策模型	预训练算力需求大	决策数据集，包括环境特征集、博弈规则集、策略行为集等	仅能展示原始状态-动作数据，可读性差，缺少决策解释	在训练集中有类似任务的，泛化能力强，否则较弱
大语言模型智能体	基于既有语言大模型微调训练，算力需求小	决策任务的文本表征数据集，包括状态表征、动作表征等	以文本形式展示决策过程，可读性强，可生成决策解释	得益于大语言模型的文本处理能力，泛化能力较强

基于以上分析，本文重点研究基于大语言模型的博弈决策智能体结构设计，旨在利用大语言模型一定的泛化能力、自动学习能力和灵活性，搭建多个任务的决策链路，并在不同的游戏场景中完成有效性

验证。

2.2 特定场景智能体研发的相关工作

为了验证基于大语言模型的博弈决策

智能体结构的有效性,本文选取了一系列多样化的游戏场景对智能体进行测试,其中包括自研的《AI 运动会》(AI Sports Games),以及《谷歌足球》(Google Research Football)、《星际争霸 II》(StarCraft II)、《我的世界》(MineCraft)。对于后 3 个游戏场景,在学界或业界均有相关工作采用其他技术路线构建了智能体,并取得了一定效果。

在《谷歌足球》场景下,基于深度强化学习形成的策略可以达到较高级水平。如 WeKick 采用强化学习结合种群训练的算法路线研究单个球员的控制问题,CDS-Qmix^[13]采用强化学习离线学习算法研究 3-vs-1 多智能体合作问题,TiZero^[14]和 Light-MALib^[15]均采用多智能体强化学习结合种群训练路线研究 11-vs-11 足球中多智能体合作问题,分别都在竞赛对比中取得了不错的成绩。然而,上述工作均需要经过大量训练,如 TiZero 使用 800 块 CPU 和 2 块 A100 GPU 花费了 45 天时间,并且训练数据量庞大;同时,上述技术路线普遍缺乏可解释性和泛化能力。

《星际争霸 II》游戏自面世以来,业界涌现了多种可自主开展游戏的智能体。目前的星际争霸智能体主要采用强化学习技术构建,算力需求普遍较高,并且往往需要较多的训练数据。例如,AlphaStar^[16]采用监督学习、强化学习、自博弈训练结合的方式,使用了 12000 个 CPU 核、384 个 TPU,训练了 971000 场游戏数据,最终达成胜人类世界冠军的成绩;类似地,SCC^[17]采用相同方式,使用了更少的计算资源(大约只有 AlphaStar 的 1%)及更少的数据量,达到了同样的战胜效果;Hi-erNet-SC2^[18]采用数据挖掘结合强化学习的模式,仅使用 48 个 CPU 核、4 个 GPU、608 场游戏数据进行训练,达到了战胜星

际争霸内置困难级 AI 的效果;AlphaStar Unplugged^[19]基于离线强化学习,战胜了先前的 AlphaStar Baseline AI。以上相关工作多是基于强化学习算法,策略可解释性和可拓展性较弱。

《我的世界》作为一款多任务游戏场景,不同任务数量超过 1000,且同一任务在不同场景的表现是十分多样的。之前的研究多数依赖于 Wiki 的数据及网上已有的视频演示进行蒸馏^[20-21],在 200 多种任务上进行实验,能够顺利完成超过 70 种任务,达到获取钻石的能力。例如,JueWu-MC^[22]基于分层强化学习、表征学习、模仿学习结合的方式,使用 3 层 MLPs 配合 ReLU 激活函数的深度神经网络,训练 6000 万样本。《我的世界》游戏智能体在获取创造任务上表现良好,但同样存在可解释性弱和可拓展性弱的问题。一些最新的大语言模型智能体工作也达到了较高的水平,如 DEPS^[21]通过大语言模型加提示词(prompt)的方法,应用规划器(planner)加控制器(controller)的结构,鲁棒地完成了超过 70 种任务;GITM^[23]通过大语言模型、提示词、外接外部知识库 Wiki 的方式,解锁了《我的世界》游戏中的整个技术树。上述两种大语言模型智能体均具有获取钻石的能力。

3 博弈决策智能体结构设计

基于大语言模型,本文设计了博弈决策智能体结构,如图 1 所示。该博弈决策智能体结构在大语言模型的基础上,通过环境状态文本表征、环境动作文本表征、专家知识注入、有监督微调训练等关键技术,适应博弈场景的特定需求。

3.1 智能体结构层次划分

使用本博弈决策智能体结构构建智能




图1 基于大语言模型的博弈决策智能体结构概览

体并进行训练和推演的过程，可分为3个层级：①大模型离线微调训练；②智能体在线决策；③仿真场景交互推演。

3.1.1 大模型离线微调训练

大语言模型使用通用语料库完成预训练，具有强大的语言理解和生成能力，但针对特定的博弈对抗场景和任务，缺乏必要的领域知识，因此，将预训练的大语言模型直接用于特定场景的智能体构建，很难在博弈对抗中取得令人满意的效果。为了解决这一问题，需要在特定场景下收集历史上人类或智能体参与者的决策数据，构建训练集，用于对大语言模型的微调训练，使模型通过模仿其他参与者获得对该场景、该任务的博弈决策知识。

3.1.2 智能体在线决策

在决策过程中，针对实时的状态，先由微调后的大语言模型做出高层决策，再由底层的智能体（相对地称为“小模型”，由规则控制实现，或通过强化学习等算法训练而成）完成局部的精细操作，实现“大模型-小模型”协同的决策过程。在整个决策中，微调后的大语言模型扮演“大脑”的角色，负责对实时态势进行分析、推理、规划，而底层智能体则扮演“双

手”，负责具体指令的实施。

3.1.3 仿真场景交互推演

模拟实际场景构建仿真交互场景，作为智能体的训练场和演练场。仿真场景越精细，训练和评估的样本质量越好；仿真场景越高效，训练和评估的样本采集速度越快。上述两个维度往往难以同时兼顾，需要根据实际任务特点和需求来进行权衡。一般来说，对安全性、稳定性要求较高的场景，需要适当牺牲仿真效率，构建更高精度的仿真环境；反之，可以使用较低精度的仿真环境，通过更大的样本量提升智能体训练质量和评估效果。

3.2 关键技术

为了发挥大语言模型在博弈决策中的作用，在本博弈决策智能体框架中，采用了4个关键技术提升大语言模型在特定任务下的决策效果：①环境状态文本表征；②环境动作文本表征；③专家知识注入；④有监督微调训练。

3.2.1 环境状态文本表征

对环境状态的文本表征是决策大语言模型语境理解的基础，博弈环境如何文本化并统一表征，也是博弈决策智能体首先要关

注的问题。博弈决策环境具有状态空间维度高、决策要素多、奖励信息难以显式化的特点,而面向特定任务学习时,可以通过状态空间对齐和形式化表征将环境统一表达。其中状态空间特指任务状态的所有可能值的集合,包含状态特征、动作、奖励;状态空间对齐指环境表征统一化,将序列化环境交互数据转换为统一表征的状态文本。框架设计了规则引擎转换器,基于规则地将结构化状态数据转换为文本描述数据,其中文本、连续值、离散值等不同种类内容依据以下原则进行转换。

(1) 文本:对原文本进行总结精练,仅抽取关键部分;

(2) 连续值:设定有限个区间,将连续值离散化;

(3) 离散值:存储为等级文本。

以下为《AI 运动会》游戏场景与《星际争霸 II》游戏场景下的状态文本表征示例。

《AI 运动会》游戏状态文本表征:

(1) 状态特征:包括游戏信息和实时观测两个部分。游戏信息主要有游戏时间、实时得分、本方运动状态等数据;实时观测表示为 40×40 的二维矩阵,记录智能体所见的视野内容,包括障碍物、地面指示线、其他智能体等。

(2) 动作:由动力大小 ($-100.0 \sim +200.0$) 和转向角度 ($-30.0^\circ \sim +30.0^\circ$) 两个实数组成。

(3) 奖励:根据具体场景规则确定,当智能体触碰目标标志线或惩罚标志线时,给予正或负奖励值。

《星际争霸 II》游戏状态文本表征:

(1) 状态空间:包括游戏信息和实时观测两个部分。游戏信息主要有游戏时间、本方资源状态、本方科技等级、本方单位状态等数据;实时观测主要有本方可

见区域中的障碍物、敌方单位位置与状态等信息。

(2) 动作:对于本方每一个单位,可以选择采取以下某个动作:①No-np (若 $\text{health} > 0$, 则无法执行此动作;若 $\text{health} = 0$, 则只能执行此动作);②STOP (停止,除去 $\text{health} = 0$ 情况,stop 动作一直可执行);③向上移动 (Direction. NORTH);④向下移动 (Direction. SOUTH);⑤向右移动 (Direction. EAST);⑥向左移动 (Direction. WEST);⑦~n. 其他动作。

(3) 奖励:根据我方资源增减、单位战损等给予不同权重的奖励值。

3.2.2 环境动作文本表征

决策问题往往是领域相关的,若动作概念没有对齐,很难用零样本/少样本训练一个表现良好的智能体。因此,本文构建了一套跨任务、从抽象到具体的博弈决策任务体系,提升智能体的泛化能力。

根据针对的对象不同,博弈决策任务体系分为竞争、合作、管理三大概念,分别用于制定针对敌方实体、友方实体、我方实体的策略。同时,根据竞争的资源不同、合作参与者之间的协作方式和目标不同,以及管理控制的对象不同,进一步分化为空间竞争、物资竞争、人员竞争、联盟构建、资源共享、信息共享、团队协作、物资管理、空间控制、信息控制共 10 类博弈任务。更进一步地,列举出了 44 种动作以囊括多场景下博弈行动,详见图 2。目前版本的博弈决策任务体系中涵盖了《AI 运动会》《谷歌足球》《星际争霸 II》《我的世界》等多种博弈场景的主要任务类型。

博弈决策任务体系旨在建立一个系统性的框架,以帮助理解和分析各种博弈情境中涉及的不同任务和行动。通过将博弈过程分解为不同层次和任务,可以更清晰




图2 博弈决策任务体系

地识别和理解在博弈中涉及的关键动作和策略，有助于制订更有效的决策和行动计划。此外，博弈决策任务体系还有助于指导实践中的行动，提高决策的质量和效果，从而更好地适应和应对不同领域的博弈挑战。

博弈决策任务体系限定了大模型产生的高层任务类型，为智能体构建提供了参考；在实际执行时，体系中的任务或动作

概念会由底层小模型进一步拆分成从数步到数十步不等的动作组合和环境交互来实现。

3.2.3 专家知识注入

在特定任务上进行决策时，为了提升最终效果，往往需要结合相关领域的专家知识，或者既有方法（如组合优化算法、规则控制算法等）。

将增量的专家知识注入模型有几种常见的方式：规则控制模块、外置知识库和提示工程（prompt engineering）。

规则控制模块将算法规则类的专家知识以代码或程序形式实现，同时提供必要的模块功能和接口说明，供大语言模型理解和调用。外置知识库的方式一般基于向量数据库，将概念解释类的专家知识文本向量化处理后存储，并基于相似度检索来将问题链接到知识库中的内容从而给出答案，辅助大语言模型完成特定领域内的文本理解和生成。通过提示工程注入专家知识，即将示例格式类的专家知识拼接到提示词中作为大语言模型的输入，可以让大语言模型模仿学习参考示例、约定输出格式等。

本文提出的博弈决策智能体结构，结合上述3种方式实现领域专家知识注入模型，各方法互补式地从格式规范、注入知识灵活性、场景特异性等方面健全预训练模型在博弈决策领域的技术应用，从而构建更鲁棒的专家知识模块。

3.2.4 有监督微调训练

有监督微调训练（Supervised Fine Tuning, SFT），是对原始预训练模型的知识增量训练方法，适合针对特定场景，使用结构化的训练数据集训练更新大语言模型的权重，形成具有领域专用知识的大语言模型。但相对于专家知识注入技术，有监督微调训练存在对预训练知

识灾难性遗忘的缺点（从一个了解海量知识的模型“退化”为注重微调训练知识的模型），因此，训练数据需要有充分的代表性。

由于决策任务具有显著特异化，不同博弈决策场景的背景、决策逻辑等知识差距较大，因此，需要在大模型上接入针对不同场景的专用知识，并通过有监督训练方式，供预训练模型学习。在技术层面上，首先需要获取高质量结构化、有标注的序列数据，再从这些数据中学习推理逻辑链路，通过预训练大模型的微调训练方法更新模型权重，最终形成具有博弈场景专用决策知识的大语言模型。

随着技术的发展，业界涌现出越来越多的大模型且模型参数越来越多，如 GPT3 已经达到 1750 亿的参数量，在这种情况下，传统的监督微调方法已经不再能适用现阶段的大参数量模型。为了解决微调参数量太多的问题，同时也要保证微调效果，本文提出的博弈决策智能体结构中，采用了参数高效的微调方法（Parameter Efficient Fine Tuning, PEFT），包括低阶自适应^[24]（Low-Rank Adaptation, LoRA）和 P-tuning V2^[25]（Prefix tuning V2）。两

者在底层实现上原理较为不同，但都是更高效地调整预训练模型参数的方法。

4 场景验证与结果分析

为了验证基于大语言模型的博弈决策智能体结构能够在不同场景下构建有效的智能体，本文设计了包含 4 个游戏场景的验证实验。

4.1 实验场景设置

实验选择的 4 个游戏场景为：《AI 运动会》《谷歌足球》《星际争霸 II》《我的世界》，各场景具体介绍及设置如下。

1. 《AI 运动会》游戏

《AI 运动会》游戏是本研究团队自研的智能体算法公开测试环境，包含的一系列丰富有趣的体育运动类任务集合，如足球、跑步、摔跤等。各任务中，智能体具有相同的底层感知和运动机理，但具有不同的观测视野、行动规范、任务目标等。本实验选取了如图 3 所示 3 个游戏场景对智能体进行测试，验证基于大语言模型的博弈决策智能体的学习能力和泛化性。3 个场景的具体特点分别如下。




图 3 《AI 运动会》游戏任务

（1）摔跤任务：目标是保持在圆形擂台上（不离开外侧圆形区域边界）的时间长于对手，博弈策略需要在保证本方不离

开擂台的前提下，尝试将对方撞出擂台。

（2）跑步任务：目标是先于对手触碰终点标志线，博弈策略需要通过地面上的

箭头标志线确定终点方向，在行进过程中避免撞墙导致动力损失，同时可以通过阻挡对手取得优势。

(3) 足球任务：目标是在规定时间内球进入对方球门的次数超过进入本方球门的次数，博弈策略需要在进攻时尽量控制球躲避对方拦截，而防守时则尽量阻挡对手突破。

2. 《谷歌足球》

《谷歌足球》是现实足球场景的仿真游戏环境，在决策过程中同时包含了竞争与合作的博弈形式。本实验选择《谷歌足球》游戏的 11-vs-11 任务作为验证场景，两方对抗，每方将控制一支球队中的 11 名球员，采用标准的足球规则。《谷歌足球》游戏场景具有多智能体合作，双方对抗，状态空间规模大等特点，其仿真环境的仿真度较高，如图 4 所示。



图 4 《谷歌足球》游戏场景

3. 《星际争霸 II》

《星际争霸 II》是一款即时战略游戏，游戏双方采集矿产获得资源，用于建筑物建造、科技研发、军队招募等，以摧毁对方单位为最终目标。在博弈过程中，需要考虑资源的采集和合理利用、建筑科技军队的构建顺序、进攻与防守战术等多方面决策，状态和动作维度大，游戏场景如图 5 所示。



图 5 《星际争霸 II》游戏场景

4. 《我的世界》

在《我的世界》游戏场景中，智能体面对多样的客观环境，并需要完成多种类型的任务，如图 6 所示。本实验选择在《我的世界》的创造模式中进行测试，在该模式下，智能体可以无限制地获取物品和放置方块，并且智能体的行动不会受到生命值和饥饿值限制的阻碍，决策可以更专注于探索新的区域和制造新的物品。



图 6 《我的世界》游戏场景

4.2 实验步骤

4.2.1 基础大语言模型选择

本实验从开源大语言模型中选取了来自清华大学的 GLM-6B 模型（第 2 版和第 3 版），以及来自 Meta 的 LLaMA-7B 模型（第 2 版），作为智能体结构中的基础大语言模型。具体模型信息如表 2 所示。

表 2 基础大语言模型信息

模型	版本	参数量/B	上下文长度/K	来源
GLM	2	6	32	清华大学
GLM	3	6	32	清华大学
LLaMA	2	7	4~100	Meta

4.2.2 提示词设计

大语言模型通过提示词 (prompt) 了解当前场景的元信息和实时状态, 主要包含游戏背景、状态、指令问题、动作示例等。每个场景根据各自的特点设计了合适的提示词。如在《星际争霸 II》游戏中, 让语言模型代入《星际争霸 II》游戏的场景, 扮演《星际争霸 II》专业助手, 依据《星际争霸 II》专业的分析方式对数据进行详细综合分析, 并给出合理决策;《谷歌足球》的提示词包含游戏名字, 状态信息如球权归属, 足球位置概括和防守态势分析, 以及可行动作集合;《我的世界》游戏提示词包含课程 (curriculum)、技能描述、下一步即时动作等的信息。图 7 展示了该提示词框架在《星际争霸 II》中的运用。

4.2.3 状态动作设计

为各场景设计状态集合和高层动作集合旨在将游戏环境中的状态与动作特征化和离散化, 便于自动化生成详略得当的自然语言文本表征, 适配博弈决策智能体的输入输出模态。特别地, 动作设计参考了博弈决策任务体系中的任务分类。图 7~图 10 分别展示了《星际争霸 II》《谷歌足球》《我的世界》场景的具体状态动作集合设计。

4.2.4 训练数据收集与整理

大语言模型微调训练数据取自游戏环境中智能体的行为交互数据, 为了保证数据质量, 一般选用表现良好的游戏智能体产生数据样本。

例如,《星际争霸 II》数据来自 GPT3.5-tutor-16k 模型与 TextStarCraft2 交互得到的历史数据, 采用共 20000 余条 GPT3.5-tutor-16k 和 GPT4 模型与 TextStarCraft2 交互中的数据。

《谷歌足球》来自专家策略推理, 其中专家策略由高层策略逻辑结合底层强化学习模型组成。数据格式为提示词及专家动作标注, 数据量为 8000 余条, 储存为 JSON 文件格式。数据采集步骤如下。

(1) 挑选底层谷歌足球的强化学习模型;

(2) 编写高层谷歌足球的专家策略;

(3) 集成构建高层—底层智能体;

(4) 将智能体放入谷歌足球环境中 (对手为简单电脑 bot), 与环境交互产出数据 (格式为提示词—高层动作—底层动作)。

《我的世界》数据来自 GPT4 与游戏环境的交互数据和基于规则的智能体的行为回放数据, 将十种观测整理为自然语言, 输入大语言模型, 根据观测规划智能体任务, 并用自然语言描述, 从向量数据库中检索最相似的动作代码, 作为智能体的决策动作输出, 如图 11 所示。

4.2.5 离线微调训练

针对每个场景, 分别通过微调训练 (fine tuning) 的方式, 使用该场景对应的训练数据集对大语言模型进行训练, 形成具有场景特定知识的大语言模型, 完成专家知识注入。

4.2.6 临机决策

临机决策是将微调后的大语言模型做出的高层决策落实到最底层行动指令的过程。临机决策流程可分为观测、决策、行动 3 个环节。

(1) 观测: 将从游戏环境中获取的结构化观测数据表征为状态描述文本, 组成




图7 以《星际争霸Ⅱ》为例的系统提示词示例

状态集合:	游戏时间、资源信息、部队信息、建筑信息、单位信息、研发信息、敌人建筑信息、敌人单位信息。
动作集合:	
训练:	TRAIN UNIT (TRAIN PROBE, TRAIN ZEALOT, TRAIN ADEPT, TRAIN STALKER, TRAIN SENTRY, ...) (共19种),
制造:	BUILD STRUCTURE (BUILD PYLON, BUILD ASSIMILATOR, BUILD NEXUS, BUILD GATEWAY, BUILD CYBERNETICSCORE, ...) (共15种),
研发:	RESEARCH TECHNIQUE (RESEARCH WARPGATERESEARCH, RESEARCH PROTOSSAIRWEAPONSLEVEL1, RESEARCH PROTOSSAIRWEAPONSLEVEL2, ...) (共26种),
侦察:	SCOUTING PROBE, SCOUTING OBSERVER, SCOUTING ZEALOT, SCOUTING PHOENIX,
进攻:	MULTI-ATTACK,
撤退:	MULTI-RETREAT,
其他:	CHRONOBOOST NEXUS, CHRONOBOOST CYBERNETICSCORE, CHRONOBOOST TWILIGHTCOUNCIL, CHRONOBOOST STARGATE, CHRONOBOOST FORGE, EMPTY ACTION.

图8 《星际争霸Ⅱ》状态动作集合

状态集合:	Ball ownership球权归属、Ball position足球位置概括、Defensive status防守态势分析。
动作集合:	
撤退:	All pull back阵型回撤防守,
进攻:	Offending进攻模式,
防守:	Defending防守模式,
抢夺:	Pressure逼抢模式。

图9 《谷歌足球》状态动作集合

状态集合:

Biome 周围环境、Time 当前时间、Nearby blocks 附近方块、
Health 当前的健康状态、Hunger 饥饿等级、
Position 当前状态、Equipment 当前装备、
判断是否需要切换装备、Inventory 库存、
Chests 箱子/存放物品、Context 任务的上下文。

动作集合:

收集: Mine 1 wood log, Obtain 10 wood logs,
Mine 10 cobblestone, Mine 5 coal ores,
Mine 5 copper ores,
储备管理: Kill 3 chickens,
制造: Craft a crafting table, Craft a wooden pickaxe,
Craft a wooden axe, Craft a wooden shovel,
Craft a stone pickaxe, Craft a furnace,
Smelt 5 raw copper, Craft a stone sword,
探索: Obtain 10 wood logs again.

图 10 《我的世界》状态动作集合

- action: 写js代码的任务
 1. "You are a helpful assistant that writes Mineflayer javascript..."
 2. 精确任务
- decompose_task: 将任务分解为子任务
 1. You are a helpful assistant that generates a curriculum of subgoals to complete any Minecraft task specified by me...
- qa task 2: 回答问题, 解释怎么解决问题
 1. "You are a helpful assistant that answer my question about Minecraft" "content='Question: How to mine 3 oak logs in Minecraft?' " answer: To mine 3 oak logs in Minecraft...
- self-verification: 自我验证, 输入一个任务, 分析是否能完成
 1. self-verification "You are an assistant that assesses my progress of playing Minecraft and provides useful guidance" "You should only respond in JSON format as described below: { " reasoning ": " reasoning ", " success ": boolean, " critique ": " critique ", }" Ensure the response can be parsed by Python ** json . loads **, e . g . : **no trailing commas, no single quotes**, etc .
 2. Here are some examples : INPUT : Inventory (2/36) : { ' oak_log ':2, ' spruce_log ':2} Task : Mine 3 wood logs RESPONSE : { " reasoning ": " You need to mine 3 wood logs . You have 2 oak logs and 2 spruce logs , which add up to 4 wood logs .", " success ": true , " critique ": "" },
- skill description: function 函数描述,
 1. 抽取少于6句的summary, 不能提函数名, 出现bot.chat之类的字眼,
 2. "You are a helpful assistant that writes a description of the given function written in Mineflayer javascript code..."
- curriculum: 提出下一个任务该做什么 the next task
 1. 生成任务 "Mine [quantity] [block]", " Craft [quantity] [item]"
 2. You are a helpful assistant that tells me the next immediate task to do in Minecraft...
 3. You should only respond in the format as described below : RESPONSE FORMAT : Reasoning : Based on the information I listed above , do reasoning about what the next task should be . Task : The next task . Here ' s an example response : Reasoning : The inventory is empty now , chop down a tree to get some wood . Task : Obtain a wood log .
- 缺乏的任务: 提出任务, 涉及下一个任务
 1. ask question: "You are a helpful assistant that asks questions to help me decide the next immediate task to do in Minecraft ..." answer: Reasoning:... Question : What are the tools that you can craft using wood planks and sticks ? Concept : wood planks
 2. RESPONSE FORMAT : Reasoning : ... Question 1: ... Concept 1: ... Question 2: ... Concept 2: ... Question 3: ... Concept 3: ... Question 4: ... Concept 4: ... Question 5: ... Concept 5: ...

图 11 以《我的世界》为例的训练数据示例 (以任务区分)

提示词。

(2) 决策: 以相对较低的频率, 使用大语言模型对当前的观测信息 (以提示词的形式输入) 综合分析处理, 形成高层决策, 作为智能体的宏观行动指导。

(3) 行动: 底层智能体, 根据大语言模型给出的高层决策, 依据动作之间的组

合关系和约束关系, 完成动作分解和高频执行。

4.3 实验结果

在《AI 运动会》摔跤、跑步、足球 3 种任务中, 基于大语言模型的博弈决策智能体决策效果良好, 能够从微调训练数据

中学习开局全力加速、视野内有障碍物时避障、无障碍物时缓慢加速、方向偏移时寻找方向、方向未偏移时全力加速等决策经验，并成功应用在实际对抗中，与基于规则控制的智能体相比具有明显的优势，从而验证了技术路线的可行性。

在《星际争霸Ⅱ》《谷歌足球》《我的世界》3个复杂场景中，实验通过多种量化评估指标对基于大语言模型的博弈决策智能体进行了评测，评测结果如表3所示。

表3 博弈决策智能体在《星际争霸Ⅱ》
《谷歌足球》《我的世界》场景中评估情况

游戏场景	训练量 / k	基础大语言模型	评估指标			
谷歌足球	8		对简单AI胜率	—	—	—
		ChatGLM2 (%)	70	—	—	—
		LLaMA2 (%)	60	—	—	—
星际争霸	20		对入门AI胜场	对简单AI胜场	对中等AI胜场	对困难AI胜场
		ChatGLM3	2/2	3/3	3/3	0/2
		LLaMA2	2/2	3/3	3/3	0/4
我的世界	2		完成任务1成功率	完成任务1~5成功率	完成任务1~10成功率	完成任务1~15成功率
		ChatGLM3 (%)	60	53	52	48
		LLaMA2 (%)	40	32	26	21

可以看出，采用不同的基础大语言模型构建博弈决策智能体，在《谷歌足球》游戏中对战内置简单难度级智能体，可以分别达到70%和60%的胜率；在《星际争霸Ⅱ》游戏中，水平超过了内置中等难度

级的智能体；在《我的世界》游戏中，分别有48%和21%的成功率完成所有15项任务，最终完成较为复杂的钻石采集工作，效果不输于采用强化学习算法训练得到的智能体。从实验结果可见，使用本文提出的基于大语言模型的博弈决策智能体结构构建特定场景智能体，使用多种基础大语言模型，经过少样本的微调训练，均能在对应场景中达到初级或以上的决策水准。

5 结束语

本文提出了一种基于大语言模型与专家知识注入的博弈决策智能体结构，并设计实验对该结构构建的智能体的决策能力进行有效性验证。通过在4个游戏场景下的测试评估，实验结果验证了该智能体结构对多种类型场景、任务的适用性和决策能力。该智能体结构能够有效地应对多种复杂情况，并在博弈决策中展现出很好的性能和灵活性。

未来的研究可以从以下几个方面展开：首先，可以进一步优化智能体结构及训练流程，提升智能体构建过程的自动化水平和在复杂场景下决策的智能化水平；其次，可以探索将该智能体结构应用于更多实际场景的智能体构建中，如金融领域的投资决策、智能交通系统的优化、军事作战指挥^[26-27]等。此外，还可以考虑在该智能体结构中引入其他人工智能技术，如强化学习、进化算法等，以进一步提升智能体的自主进化能力和自适应能力。总的来说，基于大语言模型与专家知识注入的博弈决策智能体具有广阔的应用前景和研究空间，针对该方向的研究成果将为大量的实际博弈决策业务需求带来新的解决方案。

参考文献

- 1 胡浩, 赵昌军, 刘璟, 等. 基于随机博弈与 A3C 深度强化学习的网络防御策略优选 [J]. 指挥与控制学报, 2024, 10 (1): 47-58.
- 2 HU H, ZHAO C J, LIU J, et al. Network defense strategy optimization based on stochastic gaming and A3C deep reinforcement learning [J]. Journal of Command and Control, 2024, 10 (1): 47-58.
- 3 林萌龙, 陈涛, 任棒棒, 等. 基于多智能体深度强化学习的体系任务分配方法 [J]. 指挥与控制学报, 2023, 9 (1): 93-102.
- 4 REED S, ZOLNA K, PARISOTTO E, et al. A Generalist Agent [Z]. Trans. Mach. Learn. Res., 2022.
- 5 ZHEN X, FENG Q J, CHEN H R, et al. A Survey on Video Diffusion Models [J]. ACM Computing Surveys, 2023, 57, 1-42.
- 6 HONG W Y, WANG W H, LV Q S, et al. CogAgent: A Visual Language Model for GUI Agents [C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024: 14281-14290.
- 7 AHN M, BROHAN A, BROWN N, et al. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances [C]. Conference on Robot Learning, 2022.
- 8 SHAH D, OSINSKI B, ICHTER B, et al. LM-Nav: Robotic Navigation with Large Pre-Trained Models of Language, Vision, and Action [C]. Conference on Robot Learning, 2022.
- 9 YAO S Y, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models [J]. ArXiv, abs/2210.03629, 2022.
- 10 WEI J, WANG X, SCHUURMANS D, et al. Chain of Thought Prompting Elicits Reasoning in Large Language Models [J]. ArXiv, abs/2201.11903, 2022.
- 11 YAO S, YU D, ZHAO J, et al. Tree of Thoughts: Deliberate Problem Solving with Large Language Models [J]. ArXiv, abs/2305.10601, 2023.
- 12 HONG S, ZHENG X, CHEN J P, et al. MetaGPT: Meta Programming for Multi-Agent Collaborative Framework [J]. ArXiv, abs/2308.00352, 2023.
- 13 LI C, WU C, WANG T, et al. Celebrating Diversity in Shared Multi-Agent Reinforcement Learning [J]. Neural Information Processing Systems, 2021.
- 14 LIN F, HUANG S, PEARCE T, et al. TiZero: Mastering Multi-Agent Football with Curriculum Learning and Self-Play [J]. Adaptive Agents and Multi-Agent Systems, 2023.
- 15 SONG Y, JIANG H, TIAN Z, et al. An Empirical Study on Google Research Football Multi-agent Scenarios [J]. ArXiv, abs/2305.09458, 2023.
- 16 VINYALS O, BABUSCHKIN I, CZARNECKI W M, et al. Grandmaster level in StarCraft II using multi-agent reinforcement learning [J]. Nature, 2019, 575, 350-354.
- 17 WANG X, SONG J, QI P, et al. SCC: an efficient deep reinforcement learning agent mastering the game of StarCraft II. ArXiv, abs/2012.13169, 2020.
- 18 LIU R, PANG Z, MENG Z, et al. On Efficient Reinforcement Learning for Full-length Game of StarCraft II [J]. J. Artif. Intell. Res., 2022, 75, 213-260.
- 19 MATHIEU M, OZAIR S, SRINIVASAN S, et al. AlphaStar Unplugged: Large-Scale Offline Reinforcement Learning [J]. ArXiv, abs/2308.03526, 2023.
- 20 WANG Z, CAI S, LIU A, et al. JARVIS-1: Open-World Multi-task Agents with Memory-Augmented Multimodal Language Models [J]. ArXiv, abs/2311.05997, 2023.
- 21 WANG Z, CAI S, LIU A, et al. Describe, Explain, Plan and Select: Interactive Planning with Large Language Models Enables Open-World Multi-Task Agents [J]. ArXiv, abs/2302.01560, 2023.
- 22 LIN Z, LI J, SHI J, et al. JueWu-MC: Playing Minecraft with Sample-efficient Hierarchical Reinforcement Learning [J]. International Joint Conference on Artificial Intelligence, 2021.
- 23 ZHU X, CHEN Y, TIAN H, et al. Ghost in the

- Minecraft: Generally Capable Agents for Open-World Environments via Large Language Models with Text-based Knowledge and Memory [J]. ArXiv, abs/2305.17144, 2023.
- 24 HU J E, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models [J]. ArXiv, abs/2106.09685, 2021.
- 25 LIU X, JI K, FU Y, et al. P-Tuning V2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks [J]. ArXiv, abs/2110.07602, 2021.
- 26 胡晓峰, 齐大伟. 智能决策问题探讨: 从游戏博弈到作战指挥, 距离还有多远 [J]. 指挥与控制学报, 2020, 6 (4): 356-363.
- 27 HU X F, QI D W. On problems of intelligent decision-making—how far is it from game-playing to operational command [J]. Journal of Command and Control, 2020, 6 (4): 356-363.