

面向禽业幼雏跨区调拨的分阶段联合优化与高层策略增强^①



林杰圣¹, 林舒², 张海峰², 陈志¹, 应笕³

¹(南京邮电大学 计算机学院, 南京 210003)

²(中国科学院 自动化研究所 复杂系统认知与决策国家级重点实验室, 北京 100190)

³(通用决策智能研究所, 常州 213100)

通信作者: 林舒, E-mail: shu.lin@ia.ac.cn

摘 要: 针对禽业幼雏跨区调拨中本地优先、资源分层与派车执行相互耦合导致的调拨协同决策问题, 提出一种分阶段联合优化与高层策略增强方法. 构建分阶段联合优化算法 TSJO (three-stage joint optimization), 通过本地匹配、跨区协调和派车执行依次完成局部吸收、剩余供需分配和运输方案落地. 针对不同时间窗口下供需结构和执行压力变化导致固定参数难以稳定适配的问题, 进一步引入近端策略优化 (proximal policy optimization, PPO) 算法, 在预定义策略模板之间进行窗口级自适应选择, 形成 PPO-TSJO. 实验结果表明, TSJO 相较全局贪心调拨算法 GGD (global greedy dispatch)、全局线性规划调拨算法 GLPD (global linear programming dispatch) 和分层贪心调拨算法 LGD (layered greedy dispatch), 在欠配量、欠配率、总调拨运输成本和单位需求运输成本方面表现更优; PPO-TSJO 相较 TSJO 进一步降低欠配量和欠配率, 并使运输成本基本稳定且略有下降, 运行时间总体保持稳定. 结果验证了本文所提方法在需求满足、成本控制和执行落地方面的有效性.

关键词: 禽业幼雏跨区调拨; 分阶段联合优化; 混合整数规划; 高层策略增强; 近端策略优化

引用格式: 林杰圣, 林舒, 张海峰, 陈志, 应笕. 面向禽业幼雏跨区调拨的分阶段联合优化与高层策略增强. 计算机系统应用. <http://www.c-s-a.org.cn/1003-3254/10347.html>

Stage-wise Joint Optimization and High-level Policy Enhancement for Cross-regional Poultry Chick Dispatching

LIN Jie-Sheng¹, LIN Shu², ZHANG Hai-Feng², CHEN Zhi¹, YING Jian³

¹(School of Computer Science, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

²(National Key Laboratory of Cognition and Decision Intelligence for Complex Systems, Institute of Automation, Chinese Academy of Sciences, Beijing 100190, China)

³(AI Lab, The Yangtze River Delta, Changzhou 213100, China)

Abstract: To address the collaborative dispatching decision problem caused by the mutual coupling of local priority, hierarchical resource allocation, and dispatch execution in cross-regional poultry chick dispatching, this study proposes a stage-wise joint optimization and high-level policy enhancement method. First, the three-stage joint optimization (TSJO) algorithm is developed to sequentially complete local absorption, remaining supply-demand allocation, and transportation plan implementation through local matching, cross-regional coordination, and dispatch execution. To address the challenge of difficult fixed parameter adaptation under varying supply-demand structures and execution pressure across different time windows, this study further introduces the proximal policy optimization (PPO) algorithm to perform window-level adaptive selection among predefined strategy templates, forming PPO-TSJO. Experimental results show

① 基金项目: 复杂系统认知与决策国家级重点实验室自主部署课题 (ESSPFZ0109)

收稿时间: 2026-06-01; 修改时间: 2026-06-22, 2026-07-06; 采用时间: 2026-07-20; csa 在线出版时间: 2026-09-10

that TSJO outperforms the global greedy dispatch (GGD), global linear programming dispatch (GLPD), and layered greedy dispatch (LGD) algorithms in terms of the unmet quantity, unmet rate, total dispatch transportation cost, and transportation cost per demand. Compared with TSJO, PPO-TSJO further reduces the unmet quantity and unmet rate, keeps transportation cost basically stable with slight reductions, and maintains generally stable runtime. The results verify the effectiveness of the proposed method in demand satisfaction, cost control, and dispatch execution.

Key words: cross-regional poultry chick dispatching; stage-wise joint optimization; mixed integer programming; high-level policy enhancement; proximal policy optimization (PPO)

禽业幼稚跨区调拨是大型禽业集团运营中的关键环节,其决策质量直接关系到需求满足水平、运输组织成本以及后续养殖环节的稳定性.与一般静态供需平衡问题不同,该类场景同时受到本地优先、资源分层、时效敏感、小批量组织和派车执行可行性等多重业务约束影响.例如,出现局部缺口时,应优先在本地消化,减少不必要的跨区调拨;在跨区协调时,不仅需要保证供需层面可行,还要满足派车组织、批量碎片化控制和运输条件限制.因此,如何在真实业务约束下实现本地匹配、跨区协调和派车执行的统一决策,构成了一个具有挑战性的优化问题.

现有研究已为本文提供了必要基础.在家禽供应链领域, Brevik 等^[1]采用优化模型研究肉鸡生产供应链计划问题, Solano-Blanco 等^[2]采用集成计划模型将生产、库存和配送等环节纳入统一决策框架,并进一步在生产计划中考虑肉鸡生长不确定性的影响^[3]. Yazdekhasti 等^[4]构建多周期、多模式随机供应链模型,用于处理不确定环境下禽业供应链的跨周期和多运输方式协调问题.陈栋等^[5]针对大型禽业企业雏鸡配送任务,采用订单位置聚类与车辆调度优化模型处理订单空间跨度较大带来的车辆组织问题,说明该类场景具有明确的企业需求和实际应用背景.

从物流优化和生鲜配送研究看,车辆路径问题、时间窗约束和易腐品配送优化已形成较多成果. Dantzig 等^[6]通过数学规划形式描述卡车调度问题,奠定了车辆路径优化的基本形式. Solomon^[7]针对带时间窗车辆路径问题设计求解算法, Toth 等^[8]、 El-Sherbeny^[9]分别对车辆路径问题及其求解方法进行了系统整理.在此基础上, Zhang 等^[10]面向现实约束车辆路径问题设计混合算法, Vidal 等^[11]和 Braekers 等^[12]进一步梳理了多属性车辆路径问题的约束类型和求解方法.针对时效性和易腐性较强的配送场景, Amorim 等^[13]将食品易腐性

因素纳入车辆路径决策分析, Vahdani 等^[14]采用启发式和元启发式算法求解易腐品生产-库存-路径协同问题, Ullrich^[15]通过集成建模处理机器调度与车辆路径协同问题, Devapriya 等^[16]通过集成调度模型研究易腐产品生产与配送协同问题, Soysal 等^[17]将运输成本与排放因素纳入食品物流网络模型,用于兼顾经济性和环境影响.国内方面,邵举平等^[18]构建带时窗的生鲜农产品配送 VRP 模型,张源凯等^[19]构建订单分配与物流配送联合优化方法,用于协调订单履约与配送组织,侯宇超等^[20]、汪涛等^[21]和詹长书等^[22]分别采用精英蚁群、改进人工蜂群和改进蚁群算法研究生鲜或鲜活农产品配送路径优化问题,以提升复杂配送场景下的路径求解效果.

上述研究为家禽供应链建模、车辆路径优化和生鲜易腐品配送提供了方法参考,但仍难以直接覆盖禽业幼稚跨区调拨的业务特征.现有方法多聚焦生产计划、配送路径或车辆调度中的单一层面,对本地优先吸收、跨区协调分配与运输执行落地之间的闭环联动考虑不足.同时,幼稚调拨还受资源层级、批量组织、车次安排和运输落地能力的共同影响.因此,有必要将本地匹配、跨区协调和派车执行纳入同一决策流程.

近年来,强化学习在组合优化、车辆路径、生产计划与供应链管理等方向受到广泛关注. Mazyavkina 等^[23]对强化学习在组合优化问题中的应用进行了系统梳理, Nazari 等^[24]将强化学习用于车辆路径问题求解, Kool 等^[25]进一步采用注意力机制学习路径构造策略,为复杂路径决策提供了数据驱动思路. Estes 等^[26]和 Rolf 等^[27]总结了强化学习在生产计划与供应链管理中的应用,说明其可用于处理动态计划和供应链决策问题.相关研究表明,强化学习可作为复杂优化问题中的策略学习工具.其中,近端策略优化 (proximal policy

optimization, PPO) 由 Schulman 等^[28]提出, 具有训练稳定、实现相对简洁等特点. 在本文场景中, 不同时间窗口下的供需紧张程度、资源层级结构和运输执行压力存在差异, 固定参数配置难以兼顾保供、成本控制和反碎片化效果. 因此, 本文引入基于 PPO 的高层策略增强机制, 根据窗口状态在预定义策略模板之间进行自适应选择, 以提升算法在不同供需场景下的参数适配能力.

基于此, 本文围绕脱敏后的真实企业业务数据, 研究面向禽业幼稚跨区调拨的分阶段联合优化与高层策略增强方法. 本文不将问题简化为单一步骤的供需配平, 而是将其组织为本地匹配、跨区协调和派车执行这 3 个相互衔接的阶段: 通过本地匹配优先吸收局部矛盾, 通过分层线性规划进行跨区协调并满足剩余供需要求, 再通过基于混合整数规划的派车执行阶段将分配结果转化为可实施方案. 在此基础上, 引入基于 PPO 的高层策略增强模块, 以降低固定参数配置对人工经验的依赖.

本文的主要贡献如下.

(1) 针对禽业幼稚跨区调拨这一强业务约束场景, 提出由本地匹配、跨区协调和派车执行构成的分阶段联合优化算法 TSJO (three-stage joint optimization), 使问题的局部性、层次性与执行性能能够统一表达.

(2) 在分阶段联合优化算法基础上引入基于 PPO 的高层策略增强机制, 使系统能够在不同时间窗口场景下动态选择更合适的运行模板, 提升跨窗口适应能力与综合表现.

(3) 构建规则驱动、单层全局优化、分阶段联合优化与策略增强方法的比较链条, 并通过整体结果、结构消融和 PPO 模块实验验证所提方法的有效性.

1 问题描述与基础模型构建

1.1 问题描述

本文研究禽业幼稚跨区调拨问题. 在给定时间窗口内, 多个组织单元之间存在供给与需求的不平衡, 需要通过本地消化与跨区调拨相结合的方式实现整体协调. 为便于后续建模与求解, 本文将该问题抽象为由供给节点、需求节点、资源层级和运输连接关系构成的调拨网络.

在实际业务中, 同一组织单元内部的供需应优先匹配, 仅当本地供给不足时, 剩余缺口才进入跨区调拨流程. 与此同时, 供给侧资源并非完全同质, 往往还具有幼稚周龄分档等属性差异, 不同层级资源在匹配过程中具有不同的优先顺序与使用代价. 因此, 该问题并不是简单的总量配平, 还需要在资源层级偏好下协调供需关系.

进行跨区协调时, 调拨方案结果还需要满足运输组织要求. 一方面, 调拨通常要达到一定组织规模, 过小批量会带来额外的组织成本和效率损失. 另一方面, 上层形成的分配关系还需进一步转化为可执行的运输计划, 受车辆容量、运输距离、价格档和车池覆盖范围等因素限制. 这意味着, 某一分配方案即便在数量上可行, 也可能在执行层面成本较高甚至难以落地.

基于上述特点, 本文将禽业幼稚跨区调拨问题视为一个包含本地匹配、跨区协调与派车执行的多阶段联合优化问题. 其核心在于: 在满足需求的前提下, 协调本地优先、资源分层、批量组织和运输执行等约束, 使调拨方案在保供、成本与可执行性之间取得更合理的平衡.

为直观描述禽业幼稚跨区调拨中的供给节点、需求节点、资源层级及派车执行关系, 图 1 给出了该业务场景的网络示意.




图 1 禽业幼稚跨区调拨网络示意图

1.2 符号定义

为方便形式化描述禽业幼稚跨区调拨问题中的优化目标和约束条件,本节对全文涉及的关键符号进行统一的定义和说明,详见表1。

表1 符号描述

符号	定义
I	供给节点集合
J	需求节点集合
K	资源层级集合
T	时间窗口集合
B	派车阶段需求任务集合
M	派车阶段未满足惩罚系数
R_t	时间窗口 t 内的执行车次集合
S_{ikt}	节点 i 在窗口 t ,资源层级 k 下的供给量
D_{jt}	节点 j 在窗口 t 下的需求量
d_{ij}	节点 i 到节点 j 间的调拨距离
ρ	调拨距离成本基础系数
α	小批量调拨惩罚系数
θ	小批量调拨敏感阈值
β_k	资源层级 k 的惩罚系数
$q_{\min}$	参考最小批量阈值
η	本地缺口容忍率
Q	车辆容量上限
v_b	任务 b 在派车阶段的未满足量
$\phi(\cdot)$	小批量调拨惩罚函数
m_{ikt}	节点 i 在窗口 t ,资源层级 k 下的本地匹配量
x_{ijkt}	节点 i 向节点 j 调拨层级 k 的资源数量
y_{ijt}	节点 i 和节点 j 之间是否发生调拨的0-1变量
u_{jt}	节点 j 在窗口 t 下的未满足需求量
C_r	车次 r 的实际运输费用

1.3 基础优化目标

禽业幼稚跨区调拨的目标是在尽量满足各需求节点需求的基础上,降低实际执行中不必要的跨区流动和碎片化运输,并兼顾不同资源层级在实际匹配中的使用偏好。根据业务特点,本文将未满足需求量作为主要优化方向,同时将运输距离、小批量组织代价和资源层级惩罚纳入调拨成本,构建综合优化目标如下:

$$\min Z = \sum_{t \in T} \sum_{j \in J} u_{jt} + \sum_{t \in T} \sum_{i \in I} \sum_{j \in J} \sum_{k \in K} (\rho d_{ij} x_{ijkt} + \alpha \phi(x_{ijkt}) + \beta_k x_{ijkt}) \quad (1)$$

其中,小批量惩罚函数 $\phi(\cdot)$ 定义为:

$$\phi(x_{ijkt}) = \begin{cases} q_{\min} - x_{ijkt}, & 0 < x_{ijkt} < q_{\min} \\ 0, & x_{ijkt} = 0 \text{ 或 } x_{ijkt} \geq q_{\min} \end{cases} \quad (2)$$

式(1)中, Z 为综合优化目标函数值。目标函数由两

部分组成,第1部分为各时间窗口内的未满足需求量,用于体现保供要求;第2部分为调拨代价,其中3项分别刻画了跨区运输距离 $\rho d_{ij} x_{ijkt}$ 、小批量调拨 $\alpha \phi(x_{ijkt})$ 和资源层级差异 $\beta_k x_{ijkt}$ 对调拨方案的影响。式(2)表示当调拨量低于参考最小批量阈值 $q_{\min}$ 时,模型对该调拨关系施加惩罚,以减少过小批量带来的运输碎片化问题;当调拨量为0或达到参考批量阈值时,不再施加小批量惩罚。

需要说明的是,式(1)中的调拨代价是跨区协调运输的预计成本,其作用是引导模型在保供基础上形成更合理的流向关系,并不等同于实验部分统计的最终总调拨运输成本。最终总调拨运输成本由后续派车执行阶段结合实际车次、车辆容量和价格档进一步计算。

1.4 基础约束条件

在上述优化目标下,模型需满足供给容量、需求平衡、调拨关系及变量取值等约束。具体约束如下:

$$\sum_{j \in J} x_{ijkt} \leq S_{ikt}, \quad \forall i \in I, k \in K, t \in T \quad (3)$$

$$\sum_{i \in I} \sum_{k \in K} x_{ijkt} + u_{jt} = D_{jt}, \quad \forall j \in J, t \in T \quad (4)$$

$$\sum_{k \in K} x_{ijkt} \leq Q y_{ijt}, \quad \forall i \in I, j \in J, t \in T \quad (5)$$

$$x_{ijkt} \geq 0, u_{jt} \geq 0, \quad \forall i \in I, j \in J, k \in K, t \in T \quad (6)$$

$$y_{ijt} \in \{0, 1\}, \quad \forall i \in I, j \in J, t \in T \quad (7)$$

式(3)为供给约束,表示任一供给节点在给定时间窗口和资源层级下的调出量不能超过其可用供给量。式(4)为需求平衡约束,表示需求节点获得的调入量与未满足需求量之和等于该节点需求量。式(5)为调拨关联约束,用于建立调拨量与调拨关系变量之间的联系,当节点 i 与节点 j 在时间窗口 t 内未发生调拨时,对应调拨量为0。式(6)为非负约束,保证调拨数量与未满足需求量非负。式(7)为二元约束,表示节点间是否发生调拨。

1.5 问题分析

上述基础模型的目标函数和约束条件刻画了禽业幼稚跨区调拨中的基础供需匹配和调拨限制关系。其中,式(1)中的未满足需求项对应保供目标,运输距离、小批量惩罚和资源层级惩罚对应跨区流向选择中的成本与业务偏好;式(3)–式(7)则分别刻画供给容

量、需求平衡、调拨关联和变量取值等基础约束. 因此, 该模型能够从数量层面对跨区调拨中的供需关系和基本调拨限制进行形式化描述.

需要说明的是, 结合第 1.1 节的问题描述可以看出, 实际业务中的本地优先吸收、资源层级顺序、运输价格档、车辆复用和区域车池等约束并非处于同一决策层面. 若将上述约束全部纳入单一模型集中求解, 容易导致模型规模扩大、约束关系复杂和业务解释性下降. 因此, 本文设计分阶段联合优化算法 TSJO, 将求解过程拆解为本地匹配、跨区协调和派车执行这 3 个相互衔接的阶段, 以分别处理不同层次的业务约束.

具体而言, 本地匹配阶段对应同一组织单元内部供需的优先吸收, 用于减少进入跨区协调的剩余供需规模; 跨区协调阶段对应未满足需求、运输距离、小批量惩罚和资源层级惩罚共同作用下的流向优化, 用于在保供目标和调拨成本之间形成平衡; 派车执行阶段则进一步处理基础模型中未完全展开的车辆容量、价格档、区域车池和车辆复用等执行约束, 将跨区调

拨流向转化为可执行运输方案. 因此, TSJO 能够与前述基础模型中的目标函数、约束结构和实际业务流程形成对应, 适用于求解本文所描述的禽业幼稚跨区调拨问题.

2 算法设计

针对禽业幼稚跨区调拨中本地优先、资源分层和运输执行相互耦合的问题, 本文设计分阶段联合优化算法 TSJO. 该算法按照实际业务流程将调拨过程划分为本地匹配、跨区协调和派车执行这 3 个相互衔接的阶段, 以实现从局部供需吸收、剩余供需协调到运输方案落地的联合求解. 该分阶段设计能够将不同层次的业务约束分别纳入对应求解环节, 避免单一模型集中处理带来的复杂性. 在此基础上, 为提升算法在不同时间窗口下对供需结构和执行压力变化的适应能力, 进一步引入基于近端策略优化 (PPO) 的高层策略增强机制, 形成 PPO-TSJO. TSJO 及 PPO-TSJO 算法总体框架如图 2 所示.




图2 TSJO 及 PPO-TSJO 算法总体框架图

2.1 算法总体流程

TSJO 的输入包括供给数据、需求数据、节点间距离数据和车辆执行数据. 算法首先在同一组织单元内部进行本地匹配, 优先吸收可在本地解决的供需矛盾, 并得到剩余供给与剩余需求. 然后, 基于分层线性规划模型对剩余供需进行跨区协调, 形成跨区调拨流向方案. 最后, 结合车辆容量、运输距离、价格档和车池覆盖关系等执行条件, 将调拨流向方案转化为可执行派车方案.

PPO-TSJO 模块位于 TSJO 上层, 不直接生成调拨

数量或派车变量, 而是在预定义策略模板库中选择高层参数配置. 每个策略模板对应一组本地缺口容忍比例、小批量惩罚系数、资源层级惩罚系数和参考最小批量阈值等参数. 对于给定时间窗口, PPO-TSJO 根据窗口级状态特征选择相应模板, 再调用完整 TSJO 流程完成求解. 该设计在保留优化模型可解释性和稳定性的同时, 降低了固定参数配置对人工经验的依赖.

2.2 本地匹配阶段

本地匹配阶段优先处理同一组织单元内部可直接吸收的供需关系. 在实际业务中, 若本地供给能够满足

本地需求,则该部分需求不再进入跨区调拨流程;若本地供给只能部分满足需求,则先完成可匹配部分,再将剩余供给和剩余需求传递至下一阶段.该阶段能够减少不必要的跨区流动,降低后续分配和派车执行方案的求解规模.

在具体处理过程中,算法以时间窗口、组织单元和资源层级为基本匹配维度,按照资源层级优先顺序进行本地吸收.设 m_{ikt} 为节点 i 在时间窗口 t 、资源层级 k 下的本地匹配量,本地匹配后的剩余缺口可表示为:

$$g_{it} = D_{it} - \sum_{k \in K} m_{ikt} \quad (8)$$

为避免轻微缺口直接进入跨区调拨造成运输碎片化,本文设置本地缺口容忍率 η .当剩余缺口满足:

$$0 < g_{it} \leq \eta D_{it} \quad (9)$$

将其视为可由本地业务消化的阈值内缺口,不再进入跨区协调阶段.对于超过阈值的剩余缺口,则作为待协调需求进入下一阶段.

经过本地匹配后,得到剩余供给 $\bar{S}_{ikt}$ 和剩余需求 $\bar{D}_{jt}$.其中, $\bar{S}_{ikt}$ 表示本地吸收后仍可用于跨区调拨的供给量, $\bar{D}_{jt}$ 表示仍需进入跨区协调的需求量.该阶段输出的 $\bar{S}_{ikt}$ 和 $\bar{D}_{jt}$ 将作为跨区协调阶段的输入,使后续优化仅面向本地处理后仍需协调的供需关系.

2.3 跨区协调阶段

跨区协调阶段对本地匹配后仍未解决的剩余供需进行跨区协调.该阶段以各节点的剩余供给 $\bar{S}_{ikt}$ 和剩余需求 $\bar{D}_{jt}$ 为输入,在全局范围内确定供给节点与需求节点之间的调拨流向.与单层全局配平不同,该阶段在关注需求满足情况的同时,也将运输距离、小批量调拨和资源层级差异等纳入流向选择过程,有利于提升后续运输执行方案的生成质量.

为兼顾需求满足与成本控制,本文采用两步优化策略.第1步以最小化欠配水平为目标,确定当前时间窗口下可达到的需求满足水平:

$$\min \sum_{i \in T} \sum_{j \in J} u_{ji} \quad (10)$$

在获得最优欠配水平后,第2步在保持该欠配水平不变的前提下,进一步最小化期望调拨成本:

$$\min \sum_{i \in T} \sum_{i \in I} \sum_{j \in J} \sum_{k \in K} (\rho d_{ij} x_{ijk} + \alpha \phi(x_{ijk}) + \beta_k x_{ijk}) \quad (11)$$

式(10)用于确定当前供需条件下的需求满足边

界,避免调拨成本项导致不必要的需求缺口.式(11)则在该边界下进一步优化流向结构,使跨区协调结果在运输距离、批量组织和资源层级之间取得平衡.因此,该阶段并非只追求需求满足,也不是单纯最小化运输费用,而是在保证需求满足水平不被削弱的前提下,对调拨成本进行进一步优化.

需要说明的是,式(11)中的预计成本主要用于指导分配阶段的流向选择,最终总调拨运输成本仍由派车执行阶段根据实际车次、车辆容量和价格档计算.该阶段输出跨区调拨流向方案作为后续派车执行阶段的输入.

2.4 派车执行阶段

派车执行阶段将跨区协调阶段得到的跨区调拨流向方案转化为可执行运输方案.跨区调拨流向方案确定了发车日、到达日、起讫点、品种、性别和数量等调拨信息,但该结果仍属于流向层决策,尚未刻画车辆承载能力、拼车组织、区域车池和车辆复用等执行因素.因此,TSJO在派车阶段进一步构建混合整数规划模型,对调拨流向进行车次组织和车辆指派.

具体而言,TSJO将同一发车日、到达日和起讫点下的调拨需求聚合为待执行运输任务,并在品种、性别维度上保留需求明细.对于每一类运输任务,模型根据调拨数量生成候选车次,并结合路网数据确定运输距离和运输时长.在车辆选择过程中,仅允许承包区域覆盖发车节点的车辆参与对应车次指派,从而保证派车结果符合区域车池管理规则.

为贴合实际业务需求,车次费用采用分段价格档计算.当车次装载量落入不同数量区间时,对应不同单位距离单价.设 q_r 为车次 r 的总装载量, p_r 为其对应价格档单价, d_r 为运输距离,则车次费用可表示为:

$$C_r = q_r p_r d_r \quad (12)$$

在此基础上,派车执行阶段以需求承接和运输费用控制为目标,其目标函数可表示为:

$$\min \left(M \sum_{b \in B} v_b + \sum_{r \in R_t} C_r \right) \quad (13)$$

其中, B 为派车阶段的需求任务集合, v_b 为任务 b 的未满足量, M 为较大的未满足惩罚系数.第1项用于保证模型优先承接已形成的调拨需求,第2项用于降低实际派车费用.与第2阶段中的期望调拨成本不同,式(13)中的费用由具体车次、装载量、价格档和运输距离共

同决定,因而对应实验部分统计的总调拨运输成本。

此外,模型根据运输时长设置车辆冷却规则。当车辆往返时长满足当天复用条件时,车辆可在同一时间窗口内继续参与后续任务;否则,需按照运输时长折算冷却天数,并更新车辆可用状态。该机制使车辆资源在时间维度上受到出车、回库和复用规则约束,避免将车辆视为无限可用资源。

通过派车执行阶段,本文将上层调拨流向进一步细化为派车计划、车次成本明细和派车阶段未满足统计。该阶段使算法能够同时考虑调拨数量和运输执行条件,从而提高调拨方案的可落地性。

2.5 PPO 高层策略增强机制

TSJO 能够完成本地匹配、跨区协调和派车执行的分阶段联合优化,但其运行效果仍受到高层参数配置影响。其中,本地缺口容忍比例会影响需求是否进入跨区协调阶段,小批量惩罚系数和参考最小批量阈值会影响跨区流向的批量组织效果,资源层级惩罚系数

则会影响不同层级资源的使用偏好。在不同时间窗口下,供需紧张程度、本地吸收能力、资源层级结构和运输执行压力存在差异,固定参数配置难以在所有场景下保持稳定表现。因此,本文在 TSJO 基础上引入 PPO 高层策略增强机制,构建 PPO-TSJO 方法。

PPO-TSJO 并不直接生成底层调拨变量或派车变量,而是作为 TSJO 的上层策略控制器,在预定义策略模板库中选择运行参数。该设计主要基于两方面考虑:一方面,底层调拨和派车决策需要满足供给容量、需求平衡、车辆容量、区域车池和车辆复用等约束,由线性规划和混合整数规划模型求解更有利于保证结果的可行性和可解释性;另一方面,高层参数模板选择属于离散策略选择问题,可根据窗口状态在多个候选模板之间进行自适应决策。因此,本文采用 PPO 对窗口级策略模板选择过程进行学习,使算法能够在保持底层优化结构稳定的同时,提升对不同供需场景的参数适配能力。PPO 高层策略选择过程如图 3 所示。




图 3 PPO 高层策略选择逻辑图

由图 3 可以看出, PPO-TSJO 首先根据当前时间窗口的供需状态、资源层级结构和执行压力等特征构造窗口状态,再由 PPO 高层策略选择器从策略模板库中选择参数模板。被选中的模板进一步转化为 TSJO 的运行参数,并输入完整 TSJO 执行流程。TSJO 输出欠配量、运输成本和运行时间等结果指标,这些结果进一步用于构造奖励信号,反馈给 PPO 模块以更新策略选择过程。

设时间窗口状态为 s_t , 动作为 a_t 。状态 s_t 由窗口级供需特征、本地吸收特征、资源层级特征和执行压力

特征构成。动作 a_t 表示从策略模板库中选择的参数模板,可表示为:

$$a_t \in A = \{A_1, A_2, \dots, A_n\} \quad (14)$$

其中, A 为策略模板集合, A_n 表示第 n 个候选模板。本文中 $n = 12$, 完整的策略模板库见第 3.3 节。

在执行动作 a_t 后, 系统运行完整 TSJO 流程, 并根据欠配量、运输成本和运行时间等结果构造奖励函数:

$$r_t = R(unmet_t, cost_t, time_t) \quad (15)$$

其中, $unmet_t$ 表示时间窗口 t 下的未满足需求量, $cost_t$ 表示总调拨运输成本, $time_t$ 表示算法求解时间。该奖励函

数用于引导策略在需求满足、成本控制和求解效率之间取得平衡。

通过上述设计, PPO-TSJO 将原本依赖固定配置或人工经验的参数选择过程转化为数据驱动的窗口级策略选择过程。PPO 根据不同时间窗口下的供需状态、资源层级结构和执行压力选择相应策略模板, 从而为 TSJO 提供更适配当前场景的高层参数配置。该机制有助于提升算法在不同供需场景下的适应能力, 并在需求满足、成本控制和求解效率之间取得更稳定的平衡。

3 实验设计

为验证本文所提 TSJO 与 PPO-TSJO 方法的有效性, 本文基于脱敏后的真实业务数据开展实验。实验从需求满足水平、运输成本和运行效率这 3 个方面对不同方法进行比较, 并通过结构消融和策略增强实验分析各模块的作用。

3.1 数据来源与实验环境

实验数据来源于某大型禽业集团的幼雏跨区调拨真实业务记录。原始数据包括供给数据、需求数据、路网数据和车辆数据。其中, 供给数据记录各组织单元在不同时间和资源层级下的可用幼雏数量; 需求数据记录各需求节点在对应时间窗口内的需求量; 路网数据记录节点间运输距离和运输时长; 车辆数据记录车辆可用状态、核载数量、长度规格、价格档、承包区域和车池覆盖关系等执行信息。

为保护企业业务信息和节点隐私, 本文对企业名称、节点名称和部分业务字段进行了脱敏处理, 同时保留供给、需求、资源层级、路网距离、车辆容量、价格档和车池覆盖关系等调拨优化所需的关键结构特征, 以保证实验场景与真实业务过程保持一致。脱敏后的数据集将在完成脱敏与合规审查后公开, 以支持后续研究复现和方法比较。该数据能够体现禽业幼雏调拨中本地优先、资源分层、温控运输和车辆执行落地等业务特征, 对具有多节点供需协调、资源层级匹配和车辆执行约束的类似供应链场景具有一定参考意义。

实验以时间窗口为基本评估单位。根据实际业务周期, 本文将测试数据划分为 5 个窗口, 具体划分如表 2 所示。其中, W1-W4 为周级短窗, 用于评估模型在滚动调拨场景下的稳定性; W5 为覆盖完整实验周期的整月长窗, 用于评估模型在较长周期下的整体优化效果。

表 2 实验时间窗口划分

窗口	类型	时间范围
W1	短窗	2025/07/03-2025/07/09
W2	短窗	2025/07/10-2025/07/16
W3	短窗	2025/07/17-2025/07/23
W4	短窗	2025/07/24-2025/07/31
W5	长窗	2025/07/03-2025/07/31

所有方法均在相同数据、相同窗口划分和相同评价指标下运行。实验程序基于 Windows 11 操作系统和 Python 3.11.13 实现, 硬件环境为 AMD Ryzen AI7 H350 处理器、32 GB 内存。线性规划与混合整数规划模型采用 PuLP 3.3.0 建模, 并调用 CBC 2.10.3 求解器完成求解。

3.2 对比方法与实验设置

为系统评估本文提出的 TSJO 和 PPO-TSJO 方法的有效性, 实验选取了 GGD、GLPD 和 LGD 这 3 类求解方法作为对比方法。这 3 类方法均由本研究基于禽业幼雏跨区调拨场景统一实现, 分别对应实际业务中常见的规则驱动、单层全局优化和分层启发式调拨思路。具体方法介绍如下。

(1) 全局贪心调拨 (global greedy dispatch, GGD) 方法按照启发式规则在全局范围内依次完成供需匹配, 具有实现简单、运行速度较快的特点, 但难以同时考虑资源层级、批量组织和派车执行因素。

(2) 全局线性规划调拨 (global linear programming dispatch, GLPD) 方法通过单层线性规划在全局范围内协调供需关系, 能够从整体层面进行供需分配, 但缺少本地吸收和执行层优化。

(3) 分层贪心调拨 (layered greedy dispatch, LGD) 方法在贪心分配过程中引入资源层级顺序, 能够体现一定的分层匹配逻辑, 但仍难以处理本地匹配、跨区协调和派车执行之间的联动关系。

实验中, 各方法均采用相同的供给、需求、路网和车辆数据, 并在相同测试窗口及评价指标下运行。对于 TSJO 和 PPO-TSJO, 派车执行阶段均采用相同的车辆容量、价格档、区域车池和车辆复用规则, 以保证对比结果主要反映调拨决策结构和高层策略增强机制的差异。

3.3 参数设置与策略模板

TSJO 中涉及本地缺口容忍率、小批量调拨惩罚系数、资源层级惩罚系数、小批量调拨敏感阈值等高层参数。这些参数会影响本地吸收范围、跨区分配流

向以及派车执行阶段的批量组织效果. 为避免单一固定参数配置对结果造成偏置, 本文根据不同业务偏好构建策略模板库, 用于固定模板实验和 PPO-TSJO 的动作空间. 各策略模板如表 3 所示.

表 3 策略模板库

编号	η	α	β	θ	$q_{\min}$	策略含义
A_1	0.05	1.00	0.05	200	8000	平衡型
A_2	0.08	0.70	0.02	100	6000	弱保供型
A_3	0.08	0.85	0.03	200	8000	中等保供型
A_4	0.03	1.20	0.07	500	12000	弱成本控制型
A_5	0.02	1.35	0.08	800	16000	强成本控制型
A_6	0.04	1.15	0.05	500	12000	弱反碎片型
A_7	0.03	1.30	0.06	1000	16000	强反碎片型
A_8	0.05	0.95	0.01	200	8000	层级宽松型
A_9	0.05	1.05	0.10	200	8000	层级严格型
A_{10}	0.05	1.25	0.05	1000	16000	快速求解型
A_{11}	0.04	1.30	0.05	300	12000	长距离抑制型
A_{12}	0.07	0.80	0.08	300	10000	高峰保供型

表 3 中, η 表示本地缺口容忍率, α 表示小批量调拨惩罚系数, β 表示资源层级惩罚系数, θ 表示小批量调拨敏感阈值, $q_{\min}$ 表示参考最小批量阈值.

表 3 中的模板覆盖平衡型、保供型、成本控制型、反碎片化型和长距离抑制型等业务偏好. 在固定模板实验中, TSJO 默认采用平衡型模板 A_1 作为基础配置; 在 PPO-TSJO 中, 每个模板对应一个离散动作, PPO 根据窗口状态从模板库中选择对应参数组合, 再调用完整 TSJO 流程完成求解. 该设置使固定策略与自适应策略之间具有一致的对比基础.

PPO 模块采用离散动作空间设置, 动作对应表 3 中的 12 个策略模板. 策略网络采用 Actor-Critic 结构, 隐藏层维度设为 128, 优化器采用 Adam, 学习率设为 $3E-4$, clip 系数设为 0.2. 需要说明的是, PPO 模块仅用于高层策略模板选择, 不直接生成底层调拨量或派车变量.

3.4 评价指标

为评估不同方法在禽业雏跨区调拨任务中的性能, 本文采用欠配量、欠配率、总调拨运输成本、单位需求运输成本和运行时间作为评价指标. 为便于后续实验结果展示, 分别记为 $Unmet$ 、 UR 、 TDC 、 CPD 和 $Time$. 其中, $Unmet$ 和 UR 用于衡量需求满足水平, TDC 和 CPD 用于衡量运输经济性, $Time$ 用于衡量算法求解效率. $Unmet$ 的单位为万羽, UR 的单位为 %, TDC 的单位为万元, CPD 的单位为元/羽, $Time$ 的单位为 s.

欠配量 ($Unmet$) 表示在给定时间窗口内未被满足的需求总量, 其计算公式如下:

$$Unmet = \sum_{j \in J} u_{jt} \quad (16)$$

欠配率 (UR) 表示未满足需求量占总需求量的比例, 用于反映不同需求规模窗口下的相对欠配水平, 其计算公式如下:

$$UR = \frac{\sum_{j \in J} u_{jt}}{\sum_{j \in J} D_{jt}} \times 100\% \quad (17)$$

总调拨运输成本 (TDC) 表示派车执行阶段根据最终车次方案计算得到的运输费用总和, 其计算公式如下:

$$TDC = \sum_{r \in R_t} C_r \quad (18)$$

单位需求运输成本 (CPD) 表示平均每单位需求对应的运输成本, 用于比较不同规模窗口下的成本效率, 其计算公式如下:

$$CPD = \frac{\sum_{r \in R_t} C_r}{\sum_{j \in J} D_{jt}} \quad (19)$$

运行时间 ($Time$) 表示算法从读取输入数据到输出最终结果所消耗的时间, 单位为 s. 上述指标均为越低越好.

4 实验结果与分析

为验证本文方法在禽业雏跨区调拨场景中的有效性, 本文从整体性能、企业人工方案对比、结构消融和 PPO 策略增强效果这 4 个方面进行分析. 实验结果中, W1-W4 短窗表示 4 个周级窗口结果的平均值, 长窗结果表示 W5 整月窗口结果.

4.1 整体性能分析

首先比较不同方法在短窗平均和长窗结果下的整体性能. 对比方法包括 GGD、GLPD、LGD、TSJO 和 PPO-TSJO, 评价指标包括 $Unmet$ 、 UR 、 TDC 、 CPD 和 $Time$. 其中, 各指标含义及单位已在第 3.4 节中详细说明. 不同方法的整体对比结果如表 4 和表 5 所示.

由表 4 可以看出, 在短窗平均结果下, TSJO 和 PPO-TSJO 在 $Unmet$ 、 UR 、 TDC 和 CPD 这 4 个核心指标

上均优于 GGD、GLPD 和 LGD。与 GGD 相比, TSJO 的 UR 由 2.368% 降至 0.596%, TDC 由 81.88 万元降至 66.39 万元; PPO-TSJO 进一步将 UR 降至 0.514%, 说明高层策略增强能够在短窗口场景下进一步改善需求满足效果。

表 4 不同方法短窗 (4 个周级窗口 W1-W4) 平均结果对比

方法	$Unmet$ (万羽)	UR (%)	TDC (万元)	CPD (元/羽)	$Time$ (s)
GGD	11.16	2.368	81.88	0.173 1	16.51
GLPD	9.23	1.957	79.56	0.168 2	1.82
LGD	7.72	1.631	70.14	0.148 2	7.95
TSJO	2.83	0.596	66.39	0.140 4	5.71
PPO-TSJO	2.45	0.514	66.35	0.140 3	6.00

注: 加粗数值表示最优结果

表 5 不同方法长窗 (整月窗口 W5) 结果对比

方法	$Unmet$ (万羽)	UR (%)	TDC (万元)	CPD (元/羽)	$Time$ (s)
GGD	62.05	3.277	324.33	0.171 2	214.54
GLPD	40.79	2.154	316.07	0.166 9	13.29
LGD	39.75	2.099	279.73	0.147 7	102.59
TSJO	13.59	0.717	266.52	0.140 7	90.90
PPO-TSJO	11.59	0.612	266.36	0.140 6	88.89

注: 加粗数值表示最优结果

由表 5 可以看出, 在长窗结果下, TSJO 和 PPO-TSJO 仍保持较好表现。与 GGD 相比, TSJO 的 $Unmet$ 由 62.05 万羽降至 13.59 万羽, UR 由 3.277% 降至 0.717%, TDC 由 324.33 万元降至 266.52 万元。PPO-TSJO 在 TSJO 基础上进一步将 $Unmet$ 降至 11.59 万羽, UR 降至 0.612%, 同时 TDC 和 CPD 基本保持稳定。这表明 PPO-TSJO 能够在不明显增加运输成本的情况下进一步提升需求满足水平。

综合短窗和长窗结果可以看出, GGD 虽然实现简单, 但由于缺少全局协调和执行层优化, 在需求满足和运输成本方面均存在不足。GLPD 运行时间较短, 但缺少本地吸收和派车执行机制, 综合效果有限。LGD 引入了资源层级思想, 但仍难以处理跨阶段联动问题。相比之下, TSJO 通过本地匹配、跨区协调和派车执行的协同优化, 在需求满足和运输经济性方面取得了更稳定的结果, PPO-TSJO 进一步通过窗口级策略选择提升了不同场景下的适应能力。

4.2 与企业人工方案对比分析

为进一步验证本文方法在真实业务场景中的应用价值, 本文将 PPO-TSJO 与企业现行人工调拨方案进行对比。由于企业人工方案主要关注需求满足和运输费用, 本节选取 $Unmet$ 、 UR 、 TDC 和 CPD 作为评价

指标, 不再单独比较运行时间。其中, 企业人工方案结果根据业务统计口径整理, 本文方法结果采用 W5 整月窗口下的 PPO-TSJO 结果。对比结果如表 6 所示。

表 6 与企业人工方案对比结果

方法	$Unmet$ (万羽)	UR (%)	TDC (万元)	CPD (元/羽)
企业人工方案	60.83	3.212	386.03	0.203 8
PPO-TSJO	11.59	0.612	266.36	0.140 6
改进量	49.24	2.600	119.67	0.063 2
改进幅度 (%)	80.94	—	31.00	31.01

注: 加粗数值表示最优结果

由表 6 可以看出, 与企业现行人工方案相比, PPO-TSJO 在需求满足和运输成本两个方面均取得明显改善。在需求满足方面, PPO-TSJO 的 $Unmet$ 由 60.83 万羽降至 11.59 万羽, UR 由 3.212% 降至 0.612%, 下降 2.600 个百分点。在运输成本方面, TDC 由 386.03 万元降至 266.36 万元, 降幅为 31.00%; CPD 由 0.203 8 元/羽降至 0.140 6 元/羽, 降幅为 31.01%。这说明 PPO-TSJO 不仅显著降低了未满足需求量, 也降低了总运输成本和单位需求对应的运输成本。

企业人工方案主要依赖人工经验和局部规则, 在多区域供需关系、资源层级差异和车辆执行约束共同作用下, 难以同时兼顾需求满足、运输成本控制和调度效率。尤其在整月窗口下, 供需关系和车辆资源约束进一步叠加, 人工反复调整方案的成本较高, 也容易造成局部可行但整体效果不足的问题。

相比之下, PPO-TSJO 通过本地匹配、跨区协调和派车执行的分阶段优化, 将本地优先、全局流向分配和车辆执行约束纳入统一流程; 同时利用 PPO 进行窗口级策略模板选择, 提升了不同供需结构下的适应能力。由此可见, PPO-TSJO 能够在需求满足水平和运输成本控制之间取得更优平衡, 可为实际调拨决策提供有效支持。

4.3 结构消融实验

为分析 TSJO 中不同阶段对最终结果的影响, 本文进一步开展结构消融实验。在保持数据集、评价指标和主要参数设置一致的条件下, 构造两种消融变体: 一是移除本地匹配阶段, 记为 TSJO w/o Stage 1; 二是将派车执行阶段替换为简化派车规则, 记为 TSJO+simple dispatch。消融实验结果如表 7 所示。

由表 7 可以看出, 移除本地匹配阶段后, 短窗和长窗下的 $Unmet$ 、 TDC 和 $Time$ 均出现不同程度上升。这

说明本地匹配不仅能够减少不必要的跨区流动,还能降低后续分配和派车执行阶段的组织压力。在长窗场景下,TSJO w/o Stage 1的TDC由266.52万元上升至303.67万元,说明若缺少本地吸收机制,更多可本地消化的需求会进入跨区调拨,从而增加运输组织成本。

表7 结构消融实验结果

方法	短窗平均 (W1-W4)			长窗结果 (W5)		
	Unmet (万羽)	TDC (万元)	Time (s)	Unmet (万羽)	TDC (万元)	Time (s)
TSJO	2.83	66.39	6.28	13.59	266.52	101.52
TSJO w/o Stage 1	3.46	75.07	21.79	14.24	303.67	166.07
TSJO+simple dispatch	6.04	69.19	3.56	26.87	277.32	11.67

注:短窗平均表示4个周级窗口W1-W4结果的平均值,长窗结果表示整月窗口W5结果;加粗数值表示最优结果

当将派车执行阶段替换为简化派车规则后,Time明显降低,但Unmet显著上升。尤其是在长窗场景下,TSJO+simple dispatch的Unmet由13.59万羽上升至26.87万羽,表明仅依靠简化规则虽然能够缩短求解时间,但难以充分吸收车辆容量、价格档、区域车池和车辆复用等执行因素,从而影响最终需求满足水平。这说明本地匹配和派车执行均是TSJO稳定取得较优结果的重要组成部分。

综上,TSJO的性能提升并非来自单一阶段,而是来自本地匹配、跨区协调和派车执行之间的协同作用。其中,本地匹配阶段有助于减少跨区调拨规模,派车执行阶段则保证上层调拨流向能够进一步转化为符合实际业务的可落地运输方案。

4.4 PPO模块有效性分析

为验证PPO高层策略增强模块的有效性,本文将PPO-TSJO与两种固定模板方案进行对比。其中,TSJO-fixed-default表示默认采用平衡型模板 A_1 运行TSJO,TSJO-fixed-manual表示采用人工经验选择的高峰保供型模板 A_{12} 运行TSJO,PPO-TSJO表示由PPO根据窗口状态在表3所示策略模板库中自适应选择模板。考虑到该实验主要用于分析不同策略选择方式对需求满足、运输成本和运行效率的影响,本节选取Unmet、TDC和Time作为评价指标。实验结果如表8所示。

由表8可以看出,与两种固定模板方案相比,PPO-TSJO在短窗平均和长窗结果下均取得更低的Unmet。在短窗平均结果中,PPO-TSJO的Unmet为2.45万羽,低于TSJO-fixed-default的2.53万羽和TSJO-fixed-manual的2.52万羽;在长窗结果中,PPO-TSJO的

Unmet为11.59万羽,也低于两种固定模板方案。这说明窗口级策略自适应能够进一步提升需求满足效果。

表8 PPO模块有效性实验结果

方法	短窗平均 (W1-W4)			长窗结果 (W5)		
	Unmet (万羽)	TDC (万元)	Time (s)	Unmet (万羽)	TDC (万元)	Time (s)
PPO-TSJO	2.45	66.42	6.47	11.59	266.36	88.89
TSJO-fixed-default	2.53	66.24	5.41	12.08	266.26	90.59
TSJO-fixed-manual	2.52	66.46	5.73	11.99	266.85	92.77

注:短窗平均表示4个周级窗口W1-W4结果的平均值,长窗结果表示整月窗口W5结果;加粗数值表示最优结果

从运输成本看,PPO-TSJO的TDC与两种固定模板方案基本处于同一水平,未出现明显成本恶化。在短窗平均结果中,PPO-TSJO的TDC为66.42万元,介于两种固定模板方案之间;在长窗结果中,PPO-TSJO的TDC为266.36万元,低于TSJO-fixed-manual,与TSJO-fixed-default接近。这表明PPO模块并不是通过显著增加运输费用来降低欠配量,而是通过选择更合适的高层参数模板改善不同窗口下的调拨效果。

从运行时间看,PPO-TSJO的Time整体处于可接受范围内。短窗平均结果中,PPO-TSJO的Time为6.47s,略高于两种固定模板方案;长窗结果中,PPO-TSJO的Time为88.89s,低于两种固定模板方案。这说明PPO高层策略选择没有显著增加整体求解负担。

综上,PPO-TSJO的优势主要来自窗口级策略模板的自适应选择。相较于固定参数配置,PPO模块能够根据不同时间窗口下的供需结构和执行压力选择更合适的运行模板,从而在基本保持运输成本和运行时间稳定的前提下进一步降低欠配水平。

5 结论与展望

本文面向禽业幼雏跨区调拨场景,研究了一个同时受到本地优先、资源分层和运输执行约束影响的多阶段联合优化问题。针对传统规则调拨和单层全局分配方法难以同时兼顾需求满足、运输成本和执行可行性的问题,本文提出分阶段联合优化算法TSJO。该算法依次通过本地匹配、跨区协调和派车执行优化,将局部吸收、跨区调拨和运输落地纳入统一流程,使调拨方案更符合实际业务组织过程。

基于某大型禽业集团脱敏真实业务数据的实验结果表明,TSJO在Unmet、UR、TDC和CPD等核心指标上均优于GGD、GLPD和LGD等对比方法,说明

分阶段联合优化能够更有效地处理本地优先、资源层级和执行约束之间的耦合关系。结构消融实验进一步表明,本地匹配阶段和派车执行阶段均对最终结果具有重要作用,TSJO 的优势来自多阶段结构的协同作用。

在 TSJO 的基础上,本文进一步引入 PPO 高层策略增强机制,形成 PPO-TSJO。该方法不直接替代底层优化过程,而是在预定义策略模板中根据窗口状态进行自适应选择。实验结果表明,PPO-TSJO 相比固定模板方案能够进一步降低欠配水平,同时保持运输成本和运行时间基本稳定,说明窗口级策略自适应能够提升方法在不同供需场景下的适应能力。

与企业现行人工方案相比,PPO-TSJO 实现欠配率下降 2.6 个百分点,运输费用下降 31.0%。综合来看,分阶段联合优化保证了调拨方案的可解释性和可执行性,PPO 高层策略增强进一步提升了不同窗口下的参数适配能力,二者结合能够为禽业幼稚跨区调拨提供有效的决策支持。

后续研究可从以下方面进一步展开:一是引入更细粒度的运输执行约束,如多车型协同、装卸时间和车辆实时状态等因素;二是将当前窗口级决策扩展为滚动优化机制,以适应更动态的供需变化;三是进一步完善高层策略学习过程,提升策略模板选择在更多业务场景中的泛化能力。

参考文献

- 1 Brevik E, Lauen AØ, Rolke MCB, *et al.* Optimisation of the broiler production supply chain. *International Journal of Production Research*, 2020, 58(17): 5218–5237. [doi: [10.1080/00207543.2020.1713415](https://doi.org/10.1080/00207543.2020.1713415)]
- 2 Solano-Blanco AL, González JE, Gómez-Rueda LO, *et al.* Integrated planning decisions in the broiler chicken supply chain. *International Transactions in Operational Research*, 2023, 30(4): 1931–1954. [doi: [10.1111/itor.12861](https://doi.org/10.1111/itor.12861)]
- 3 Solano-Blanco AL, González JE, Medaglia AL. Production planning decisions in the broiler chicken supply chain with growth uncertainty. *Operations Research Perspectives*, 2023, 10: 100273. [doi: [10.1016/j.orp.2023.100273](https://doi.org/10.1016/j.orp.2023.100273)]
- 4 Yazdekhashti A, Wang J, Zhang L, *et al.* A multi-period multi-modal stochastic supply chain model under COVID pandemic: A poultry industry case study in Mississippi. *Transportation Research Part E: Logistics and Transportation Review*, 2021, 154: 102463. [doi: [10.1016/j.tre.2021.102463](https://doi.org/10.1016/j.tre.2021.102463)]
- 5 陈栋, 陈天恩, 姜舒文, 等. 基于订单位置聚类的雏鸡配送车辆调度优化模型. *智慧农业 (中英文)*, 2020, 2(4): 137–148.
- 6 Dantzig GB, Ramser JH. The truck dispatching problem. *Management Science*, 1959, 6(1): 80–91.
- 7 Solomon MM. Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, 1987, 35(2): 254–265. [doi: [10.1287/opre.35.2.254](https://doi.org/10.1287/opre.35.2.254)]
- 8 Toth P, Vigo D. *Vehicle Routing: Problems, Methods, and Applications*, Second Edition. Philadelphia: Society for Industrial and Applied Mathematics, 2014.
- 9 El-Sherbeny NA. Vehicle routing with time windows: An overview of exact, heuristic and metaheuristic methods. *Journal of King Saud University-science*, 2010, 22(3): 123–131. [doi: [10.1016/j.jksus.2010.03.002](https://doi.org/10.1016/j.jksus.2010.03.002)]
- 10 Zhang DF, Cai SF, Ye FR, *et al.* A hybrid algorithm for a vehicle routing problem with realistic constraints. *Information Sciences*, 2017, 394–395: 167–182.
- 11 Vidal T, Crainic TG, Gendreau M, *et al.* Heuristics for multi-attribute vehicle routing problems: A survey and synthesis. *European Journal of Operational Research*, 2013, 231(1): 1–21. [doi: [10.1016/j.ejor.2013.02.053](https://doi.org/10.1016/j.ejor.2013.02.053)]
- 12 Braekers K, Ramaekers K, van Nieuwenhuysse I. The vehicle routing problem: State of the art classification and review. *Computers & Industrial Engineering*, 2016, 99: 300–313. [doi: [10.1016/j.cie.2015.12.007](https://doi.org/10.1016/j.cie.2015.12.007)]
- 13 Amorim P, Almada-Lobo B. The impact of food perishability issues in the vehicle routing problem. *Computers & Industrial Engineering*, 2014, 67: 223–233. [doi: [10.1016/j.cie.2013.11.006](https://doi.org/10.1016/j.cie.2013.11.006)]
- 14 Vahdani B, Niaki STA, Aslanszade S. Production-inventory-routing coordination with capacity and time window constraints for perishable products: Heuristic and meta-heuristic algorithms. *Journal of Cleaner Production*, 2017, 161: 598–618. [doi: [10.1016/j.jclepro.2017.05.113](https://doi.org/10.1016/j.jclepro.2017.05.113)]
- 15 Ullrich CA. Integrated machine scheduling and vehicle routing with time windows. *European Journal of Operational Research*, 2013, 227(1): 152–165. [doi: [10.1016/j.ejor.2012.11.049](https://doi.org/10.1016/j.ejor.2012.11.049)]
- 16 Devapriya P, Ferrell W, Geismar N. Integrated production and distribution scheduling with a perishable product. *European Journal of Operational Research*, 2017, 259(3): 906–916. [doi: [10.1016/j.ejor.2016.09.019](https://doi.org/10.1016/j.ejor.2016.09.019)]
- 17 Soysal M, Bloemhof-Ruwaard JM, van der Vorst JGAJ. Modelling food logistics networks with emission considerations: The case of an international beef supply

- chain. *International Journal of Production Economics*, 2014, 152: 57–70. [doi: [10.1016/j.ijpe.2013.12.012](https://doi.org/10.1016/j.ijpe.2013.12.012)]
- 18 邵举平, 曹倩, 沈敏燕, 等. 生鲜农产品配送中带时窗的 VRP 模型与算法. *工业工程与管理*, 2015, 20(1): 122–127, 134. [doi: [10.3969/j.issn.1007-5429.2015.01.019](https://doi.org/10.3969/j.issn.1007-5429.2015.01.019)]
- 19 张源凯, 黄敏芳, 胡祥培. 网上超市订单分配与物流配送联合优化方法. *系统工程学报*, 2015, 30(2): 251–258.
- 20 侯宇超, 白艳萍, 胡红萍, 等. 基于精英蚁群算法的多目标生鲜配送路径优化研究. *数学的实践与认识*, 2018, 48(20): 50–57.
- 21 汪涛, 潘郁, 潘芳, 等. 基于改进人工蜂群算法的生鲜农产品配送路径优化. *广东农业科学*, 2018, 45(10): 143–149. [doi: [10.16768/j.issn.1004-874X.2018.10.022](https://doi.org/10.16768/j.issn.1004-874X.2018.10.022)]
- 22 詹长书, 李正娇. 基于改进蚁群算法的鲜活农产品配送路径优化. *物流技术*, 2017, 36(9): 89–91, 149. [doi: [10.3969/j.issn.1005-152X.2017.09.020](https://doi.org/10.3969/j.issn.1005-152X.2017.09.020)]
- 23 Mazyavkina N, Sviridov S, Ivanov S, *et al.* Reinforcement learning for combinatorial optimization: A survey. *Computers & Operations Research*, 2021, 134: 105400. [doi: [10.1016/j.cor.2021.105400](https://doi.org/10.1016/j.cor.2021.105400)]
- 24 Nazari M, Oroojlooy A, Takáč M, *et al.* Reinforcement learning for solving the vehicle routing problem. *Proceedings of the 32nd International Conference on Neural Information Processing Systems*. Montréal: Curran Associates Inc., 2018. 9861–9871.
- 25 Kool W, van Hoof H, Welling M. Attention, learn to solve routing problems! *Proceedings of the 7th International Conference on Learning Representations*. New Orleans: OpenReview.net, 2019. 1–25.
- 26 Estes A, Peidro D, Mula J, *et al.* Reinforcement learning applied to production planning and control. *International Journal of Production Research*, 2023, 61(16): 5772–5789. [doi: [10.1080/00207543.2022.2104180](https://doi.org/10.1080/00207543.2022.2104180)]
- 27 Rolf B, Jackson I, Müller M, *et al.* A review on reinforcement learning algorithms and applications in supply chain management. *International Journal of Production Research*, 2023, 61(20): 7151–7179. [doi: [10.1080/00207543.2022.2140221](https://doi.org/10.1080/00207543.2022.2140221)]
- 28 Schulman J, Wolski F, Dhariwal P, *et al.* Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.

(校对责编: 李慧鑫)